

Лабораторна робота N°1

Завдання 1. Варіант 1. Побудувати модель розпізнавання фонем, використовуючи ознаки з моделей навчання без вчителя

Огляд даних

TIMIT Dataset - датасет для задач розпізнавання фонем та дослідження акустичних властивостей мовлення.

Датасет містить записи 630 дикторів з 8 діалектних регіонів США (DR1–DR8). Загальна кількість аудіофайлів: 6300, з яких після зіставлення з фонемними мітками отримано 4620 пар для тренування та 1680 для тестування. Аудіо записане у форматі WAV. Фонемні мітки зберігаються у .PHN файлах у форматі `sample_start sample_end phoneme` і охоплюють 61 унікальний фонемний клас.

Структура файлів:

```
TIMIT/  
  TRAIN/  
    DR1–DR8/  
      <speaker_id>/  
        SA1.WAV, SA1.PHN, SA1.WRD  
      ...  
  TEST/  
    DR1–DR8/  
      ...
```

Кожен аудіофайл супроводжується трьома типами анотацій: `.PHN` (фонемні мітки), `.WRD` (словесні мітки), `.TXT` (текстова транскрипція). У цій роботі використовувались виключно `.PHN` файли.

Датасет, записаний у контрольованих акустичних умовах. Аудіо має дуже низький рівень фонового шуму, рівномірне покриття діалектів та ретельно верифіковані фонемні мітки з точністю до семплу.

Проблеми та особливості: відносно велика кількість класів, деякі з яких рідкісні (наприклад, `ah`, `h`, `eng`, `nx`, `ux`), дисбаланс класів (тихі паузи (`h#`, `rau`, `epi`) трапляються значно частіше за специфічні фонемні).

Опис використаних підходів

Задача розпізнавання фонем вирішувалась як frame-level класифікація: кожному фрейму SSL-моделі присвоюється мітка фонем, яка звучить в центрі цього фрейму. Використовувалась функція втрат Cross-Entropy з ігноруванням паддингу.

Аудіо (WAV) → SSL-модель (frozen) → Hidden States ($T \times 768$) → MLP класифікатор → Фонемні логіти ($T \times 61$)

SSL-моделі використовувались у замороженому режимі без fine-tuning.

Wav2Vec2 та HuBERT генерують ~50 фреймів/секунду (крок 20 мс, hop = 320 семплів). Для кожного фрейму i центральний семпл обчислюється як $\text{center} = i \times 320 + 160$. Потім знаходиться фонема з `.PHN` файлу, інтервал якої містить цей семпл.

Класифікатор

Простий двошаровий MLP:

Linear($768 \rightarrow 256$) → ReLU → Dropout(0.1) → Linear($256 \rightarrow 61$)

Кількість параметрів: 212,541 навмисно мінімальна, щоб вся складність лягала на SSL-ознаки, а не на класифікатор.

Гіперпараметри навчання:

Параметр	Значення
Оптимізатор	Adam
Learning rate	1e-3
Batch size	16
Epochs (wav2vec2)	15
Epochs (HuBERT)	10
Padding label	-100 (ignore_index)

Метрика оцінювання

Phoneme Error Rate обчислювалась як частка фреймів, де передбачена фонема не збігається з еталонною:

$$\text{PER} = (\text{кількість неправильних фреймів}) / (\text{загальна кількість фреймів})$$



Використана метрика є frame-level PER, вона відповідає обраному підходу frame-level класифікації з Cross-Entropy функцією втрат, де кожному фрейму незалежно присвоюється мітка фонем.


Порівняння SSL-моделей і шарів

Порівнювались дві SSL-моделі та кілька шарів HuBERT:

Модель	Шар	Epochs	Loss (фін.)	PER
wav2vec2-base	last (12)	15	0.9470	29.51%
HuBERT-base	layer 1 (ранній)	10	0.7907	26.92%
HuBERT-base	layer 6 (середній)	10	0.5090	19.56%
HuBERT-base	last (12)	10	0.4798	17.97%

Найкращий результат: HuBERT last layer, PER = 17.97%.





У літературі на TIMIT benchmark типові результати PER становлять 15–20% для підходів на основі SSL-моделей із простими класифікаторами. Отриманий результат 17.97% є конкурентним для frame-level класифікації з замороженим енкодером.

Гіпотези й думки, щодо отриманих результатів

HuBERT значно краще за wav2vec2, оскільки HuBERT навчається передбачати приховані кластерні мітки для замаскованих аудіо-сегментів, що змушує модель вивчати дискретні фонетичні одиниці. wav2vec2 навчається через контрастивне завдання в неперервному просторі. Оскільки завдання HuBERT ближче до фонемної класифікації, його приховані стани краще відображають фонетичну структуру сигналу.

У статті HuBERT стверджується, що середні шари краще кодують фонемну інформацію, і це частково підтверджується: шар 6 (19.56%) кращий за шар 1 (26.92%). Однак у моєму експерименті останній шар (17.97%) виявився найкращим.

Можливе пояснення: Оскільки TIMIT чистий, акуратно розмічений датасет з простими акустичними умовами, в таких умовах вищі рівні абстракції (останній шар) несуть більше корисної інформації, ніж при роботі з зашумленим мовленням реального середовища, де середні шари можуть бути стабільнішими.

Ранній шар (layer 1) гірший за останній, але кращий за wav2vec2. Можливо, це тому, що Шар 1 HuBERT вже пройшов через CNN-енкодер та перший трансформер-шар, тому він несе базову акустичну інформацію, але ще не сформував повноцінних фонетичних репрезентацій. Проте навіть ці гірші результати для HuBERT перевершують wav2vec2 last layer.

Висновки

SSL-моделі забезпечують якісні ознаки для фонемної класифікації навіть без fine-tuning. HuBERT суттєво перевершує wav2vec2. Глибина шару впливає на якість ознак: для TIMIT останній шар HuBERT є оптимальним, що може пояснюватись чистотою датасету.

Завдання 2. Варіант 1. Аудіо фільтри для покращення якості TIMIT датасету

Опис запропонованих алгоритмів фільтрування

Було розроблено чотири алгоритми фільтрування, кожен з яких вирішує окрему задачу обробки сигналу.

Pre-emphasis

Фільтр підсилює високочастотні компоненти сигналу, компенсуючи природний спад спектра мовлення на високих частотах.

Формула:

$$y[t] = x[t] - \alpha \cdot x[t-1]$$

де $\alpha = 0.97$ - коефіцієнт pre-emphasis. Фільтр є FIR-фільтром першого порядку і реалізується за один прохід по сигналу. Основна мета: підвищити відношення сигнал/шум у високочастотному діапазоні, де знаходяться важливі ознаки приголосних фонем (шиплячі, свистячі).

High-pass filter

High-pass фільтр прибирає низькочастотні компоненти сигналу нижче частоти зрізу. У реалізації використовувався цифровий biquad-фільтр (IIR другого порядку) з частотою зрізу 80 Гц.

Низькочастотний гул у такому діапазоні (гул мережі 50/60 Гц, вібрації підлоги, шум вентиляції) не несе корисної фонетичної інформації, тому його видалення теоретично може покращити якість ознак.

Spectral noise reduction

Метод зменшення шуму базується на спектральному відніманні, алгоритмі, що оцінює профіль фонового шуму зі стаціонарних ділянок сигналу і віднімає його зі спектру. Реалізовано через бібліотеку `noisereduce` з параметром `stationary=True`, що відповідає умовам TIMIT (студійний запис зі стаціонарним шумовим фоном). Параметр `prop_decrease=0.75` задає агресивність фільтрації і 75% від оціненого шуму віднімається зі спектру.

Peak normalization

Нормалізація гучності приводить всі аудіофайли до однакового рівня амплітуди:

$$y = x / \max(|x|) \cdot \text{target_level}$$

де `target_level = 0.95`. Мета: усунути варіативність гучності між різними дикторами та записами, яка може впливати на якість SSL-ознак. TIMIT містить записи від різних дикторів з різними мікрофонами та налаштуваннями, тому рівень гучності між файлами може суттєво відрізнятись.


Тестування покращення по PER метриці

Для оцінки впливу фільтрів на якість розпізнавання фонем проводилось абляційне дослідження: кожен фільтр тестувався окремо та у комбінації з іншими. В усіх експериментах використовувалась найкраща модель з Завдання 1 (*HuBERT-base (last layer)) з MLP класифікатором, 10 epoch навчання, Adam optimizer (lr=1e-3), batch size 16.

Базовий результат (без фільтрів): PER = 17.97%

Результати абляційного дослідження

Конфігурація	PER (%)	Δ PER
Baseline (без фільтрів)	17.97%	—
Pre-emphasis only	18.04%	+0.07%
High-pass only	18.09%	+0.12%
Noise reduction only	18.08%	+0.11%
Normalization only	17.90%	-0.07%
All filters combined	18.27%	+0.30%



Аналіз результатів

Жоден з фільтрів не дав статистично значущого покращення PER. Єдиний фільтр, що дав мінімальне покращення - нормалізація гучності (-0.07%). Комбінація всіх фільтрів дала найгірший результат (+0.30%) через накопиченням артефактів від кожного окремого фільтра.

Основна причина відсутності покращення у природі самого датасету. TIMIT є студійним датасетом, записаним у контрольованих акустичних умовах з мінімальним фоновим шумом. Класичні аудіо фільтри розроблені для покращення зашумлених записів реального середовища, тому на чистих студійних даних вони не мають що покращувати і навпаки можуть вносити артефакти, що погіршують якість вхідних ознак для SSL-моделі.

Також, причина може бути в тому, що SSL-модель HuBERT навчалась на нефільтрованих аудіо даних, і будь-яке фільтрування змінює статистику вхідного сигналу і потенційно виводить його за межі розподілу, на якому навчалась SSL-модель, що призводить до гіршої якості ознак.

Об'єктивні метрики для оцінки якості даних

Окрім PER, для оцінки якості аудіо даних до і після фільтрації використовувались інші метрики:

Signal-to-Noise Ratio

SNR (відношення сигнал/шум) вимірює, наскільки сильно фільтр змінив вхідний сигнал. У цьому випадку обчислювався як відношення потужності оригінального сигналу до потужності різниці між оригіналом і відфільтрованим сигналом:

$$SNR = 10 \cdot \log_{10}(E[x^2] / E[(x - y)^2])$$

Висока абсолютна величина SNR означає сильні зміни сигналу. Від'ємний SNR означає, що фільтр вніс зміни більші за оригінальний сигнал (що типово для нормалізації тихих файлів).

Short-Time Objective Intelligibility

Метрика оцінки розбірливості мовлення, що вимірює кореляцію між короткочасними спектральними огинаючими оригінального і обробленого сигналу.

PESQ (Perceptual Evaluation of Speech Quality)

Метрика, що моделює сприйняття якості мовлення людським вухом. Шкала від 1 до 4.5. Враховує розбірливість, та суб'єктивну комфортність прослуховування.

Результати метрик якості

Фільтр	SNR (dB)	STOI	Інтерпретація
Pre-emphasis	0.26	0.9965	Мінімальні зміни, розбірливість збережена

Фільтр	SNR (dB)	STOI	Інтерпретація
High-pass	13.16	0.9993	Прибирає вузький низькочастотний діапазон, майже не впливає на сигнал
Noise reduction	5.22	0.9887	Помірні зміни, незначне зниження розбірливості
Normalization	-15.72	1.0000	Сильна зміна амплітуди (тихі файли підсилюються), але розбірливість ідеальна
All combined	-13.75	0.9838	Найнижча розбірливість через накопичення ефектів фільтрів

Інтерпретація SNR для нормалізації: від'ємний SNR (-15.72 dB) не означає погіршення якості, він відображає те, що деякі файли TIMIT мають дуже малу амплітуду і нормалізація різко збільшує їх гучність. Сам сигнал при цьому не спотворюється, що підтверджується ідеальним STOI = 1.0000.

Висновки

Проведене дослідження показало, що класичні аудіо фільтри не дають покращення PER на датасеті, оскільки TIMIT студійний датасет з високою початковою якістю запису. Всі фільтри зберігають прийнятну розбірливість мовлення (STOI > 0.98), проте жоден не покращує якість SSL-ознак настільки, щоб це відобразилось на PER. Можна очікувати, що ті самі фільтри дадуть суттєве покращення на датасетах реального середовища, де присутній значний фоновий шум. У таких умовах зменшення шуму та нормалізація гучності можуть зменшити PER на кілька відсотків.